

Modelado estocástico del dengue en Cali mediante un modelo SIR y Cadenas de Markov

Elián Steven Bejarano González
Departamento de Matemáticas, Universidad Nacional de Colombia

10 de diciembre de 2025

1. Introducción

Las epidemias de enfermedades infecciosas han sido tradicionalmente modeladas mediante sistemas de ecuaciones diferenciales, entre los cuales el modelo susceptible–infectado–removido (SIR) ocupa un lugar central. En este esquema, la población se divide en tres compartimentos: individuos susceptibles a la infección, individuos actualmente infectados y capaces de transmitir la enfermedad, e individuos removidos (recuperados con inmunidad o fallecidos) [1].

En los últimos años, el dengue se ha consolidado como uno de los principales problemas de salud pública en Colombia y, en particular, en la ciudad de Cali. Los reportes oficiales del sistema de vigilancia en salud pública (SIVI-GILA) indican que durante 2024 se presentó un incremento notable en la incidencia de dengue en Cali, con más de treinta mil casos confirmados. Este comportamiento epidémico motiva el uso de modelos dinámicos que permitan describir y analizar la evolución temporal de los contagios.

Desde la perspectiva de la teoría de procesos estocásticos, el modelo SIR puede formularse en tiempo discreto como una *Cadena de Markov* cuyos estados describen la configuración del número de susceptibles, infectados y removidos en cada instante. Esta formulación es particularmente atractiva en el contexto de un curso de Cadenas de Markov, pues conecta los conceptos teóricos de procesos de Markov con una aplicación realista en epidemiología.

Adicionalmente, en la práctica los parámetros epidemiológicos (por ejemplo, la tasa de transmisión) no son conocidos con certeza y deben ser estimados a partir de datos. Los enfoques bayesianos permiten tratar estos parámetros como variables aleatorias y utilizar métodos de Monte Carlo por cadenas de Markov (MCMC) para aproximar su distribución posterior. En particular, lenguajes como JAGS facilitan la implementación computacional de estos modelos.

En este trabajo se combinan ambas ideas: por un lado, se construye un modelo SIR discreto visto como Cadena de Markov; por otro, se utiliza MCMC para estimar sus parámetros a partir de los casos semanales de dengue confirmados en Cali durante 2024.

Objetivos

Los objetivos específicos de este proyecto son los siguientes:

- Formular un modelo SIR en tiempo discreto cuya dinámica pueda interpretarse como una Cadena de Markov en un espacio de estados finito.
- Implementar dicho modelo en JAGS, utilizando métodos MCMC para estimar parámetros epidemiológicos clave (fracción susceptible inicial, tasa de transmisión y nivel de ruido en el sistema de vigilancia) a partir de los casos semanales de dengue confirmados en Cali durante 2024.
- Reconstruir las trayectorias latentes de los compartimentos susceptibles, infectados y removidos, y comparar las predicciones del modelo con los datos observados.
- Discutir las limitaciones del modelo SIR homogéneo (*null model*) al aplicarse a datos reales de dengue, y proponer posibles extensiones (por ejemplo, inclusión de estacionalidad o tamaño de población efectiva).

2. Marco teórico

2.1. Cadenas de Markov en tiempo discreto

Sea $(X_t)_{t \geq 0}$ un proceso estocástico definido sobre un espacio de estados finito $\mathcal{E}$. El proceso se denomina *Cadena de Markov en tiempo discreto* si satisface la propiedad de Markov

$$\mathbb{P}(X_{t+1} = x_{t+1} \mid X_t = x_t, \dots, X_0 = x_0) = \mathbb{P}(X_{t+1} = x_{t+1} \mid X_t = x_t), \quad (1)$$

para todo $t \geq 0$ y para cualesquiera estados $x_0, \dots, x_{t+1} \in \mathcal{E}$. Es decir, la distribución del estado futuro X_{t+1} depende únicamente del estado actual X_t y no del pasado completo del proceso.

Cuando $\mathcal{E}$ es finito, la dinámica de la cadena queda descrita por una matriz de transición $P = (p_{ij})_{i,j \in \mathcal{E}}$, donde

$$p_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i), \quad \sum_{j \in \mathcal{E}} p_{ij} = 1.$$

Se dice que un estado i es *absorbente* si $p_{ii} = 1$, es decir, si una vez que la cadena entra en i permanece allí para siempre. Este concepto resulta relevante en modelos epidémicos, donde un estado con número de infectados igual a cero suele ser absorbente.

2.2. Modelo SIR determinista clásico

El modelo SIR determinista describe la evolución temporal de una población de tamaño constante N dividida en tres compartimentos: susceptibles $S(t)$, infectados $I(t)$ y removidos $R(t)$, con $S(t) + I(t) + R(t) = N$ para todo t . La dinámica continua viene dada por el sistema de ecuaciones diferenciales ordinarias

$$\frac{dS}{dt} = -\beta \frac{S(t)I(t)}{N}, \quad (2)$$

$$\frac{dI}{dt} = \beta \frac{S(t)I(t)}{N} - \gamma I(t), \quad (3)$$

$$\frac{dR}{dt} = \gamma I(t), \quad (4)$$

donde $\beta > 0$ es la tasa de transmisión y $\gamma > 0$ la tasa de recuperación. El término $\beta SI/N$ representa el número esperado de nuevas infecciones por unidad de tiempo bajo mezcla homogénea, mientras que γI representa el flujo de individuos que abandonan el compartimento de infectados.

Este modelo es determinista: dadas las condiciones iniciales $(S(0), I(0), R(0))$ y los parámetros (β, γ) , la trayectoria es única.

2.3. Versión discreta y estocástica del modelo SIR

Para trabajar en tiempo discreto (por ejemplo, en semanas epidemiológicas) y formular el modelo como una Cadena de Markov, se considera la aproximación siguiente. Sea Δt el tamaño del intervalo de tiempo (en este trabajo, $\Delta t = 1$ semana). Bajo la formulación de procesos de Poisson, la probabilidad de que un susceptible se infecte durante el intervalo $[t, t + \Delta t]$ viene dada por

$$p_{\text{inf}}(t) = 1 - \exp\left(-\beta \frac{I_t}{N} \Delta t\right), \quad (5)$$

donde I_t denota el número de infectados al inicio del intervalo. De forma análoga, la probabilidad de que un infectado se recupere durante el intervalo es

$$p_{\text{rec}} = 1 - \exp(-\gamma \Delta t), \quad (6)$$

que en este caso no depende de t si se asume una tasa de recuperación constante.

En cada paso t , se supone que:

- Cada uno de los S_t susceptibles se infecta de manera independiente con probabilidad $p_{\text{inf}}(t)$.

- Cada uno de los I_t infectados se recupera de manera independiente con probabilidad p_{rec} .

Por lo tanto, el número de nuevas infecciones y nuevas recuperaciones en el intervalo $[t, t + \Delta t]$ se modelan como

$$\text{new_inf}_t \sim \text{Binomial}(S_t, p_{\text{inf}}(t)), \quad (7)$$

$$\text{new_rec}_t \sim \text{Binomial}(I_t, p_{\text{rec}}), \quad (8)$$

y las ecuaciones de actualización quedan

$$S_{t+1} = S_t - \text{new_inf}_t, \quad (9)$$

$$I_{t+1} = I_t + \text{new_inf}_t - \text{new_rec}_t, \quad (10)$$

$$R_{t+1} = R_t + \text{new_rec}_t. \quad (11)$$

Definiendo el estado del sistema en la semana t como

$$X_t = (S_t, I_t, R_t),$$

se observa que la distribución de X_{t+1} depende únicamente de X_t a través de las distribuciones binomiales anteriores. De este modo, $(X_t)_{t \geq 0}$ constituye una Cadena de Markov en tiempo discreto con espacio de estados

$$\mathcal{E} = \{(s, i, r) \in \mathbb{N}^3 : s + i + r = N\}.$$

El estado (o conjunto de estados) con $I_t = 0$ es absorbente, pues una vez que la epidemia se extingue no se generan nuevas infecciones en el modelo SIR básico.

En este trabajo se utilizará esta formulación discreta y estocástica del modelo SIR como punto de partida para ajustar parámetros epidemiológicos a partir de los datos de dengue en Cali mediante técnicas bayesianas y algoritmos MCMC implementados en JAGS.

3. Datos y preprocesamiento

3.1. Fuente de información

La fuente de datos utilizada en este trabajo corresponde a la base de microdatos anónimos del Sistema de Vigilancia en Salud Pública (SIVIGILA) del Instituto Nacional de Salud de Colombia (INS), para el evento *dengue* (código 210) en el año 2024. La base original, denominada `Datos_2024_210`, contiene 309 627 registros de notificaciones a nivel nacional y 72 variables relacionadas con características demográficas, clínicas y administrativas de cada caso.

Dentro de esta base, las variables de interés principales para el presente estudio fueron:

- `COD_MUN_O`, `COD_MUN_R`, `COD_MUN_N`: códigos DANE del municipio de ocurrencia, residencia y notificación.
- `INI_SIN`: fecha de inicio de síntomas.
- `FEC_NOT`: fecha de notificación.

Cuadro 1: Resumen del filtrado de la base de microdatos SIVIGILA 2024.

Etapa	Registros	Variables
Base nacional Datos_2024_210	309 627	72
Filtrado por municipio (Cali)	41 127	72
Casos confirmados	30 386	74

- **confirmados**: indicador binario que toma el valor 1 si el caso fue clasificado como confirmado y 0 en caso contrario.
- Variables de clasificación final del caso (**Estado_final_de_caso**, **nom_est_f_caso**), utilizadas para verificar la consistencia del indicador de confirmación.

3.2. Filtrado geográfico: selección de Cali

Con el fin de centrar el análisis en un contexto específico, se consideraron únicamente los casos asociados al municipio de Santiago de Cali. Para ello se aplicó un filtrado geográfico utilizando los códigos DANE de municipio:

- Se retuvieron los registros en los que al menos uno de los campos **COD_MUN_0**, **COD_MUN_R** o **COD_MUN_N** tomara el valor 76001 (código DANE de Cali).
- De manera complementaria, se verificó la concordancia con las variables de texto **Municipio_ocurrencia**, **Municipio_residencia** y **Municipio_notificacion**, buscando la cadena “CALI” de forma insensible a mayúsculas.

Tras este filtrado se obtuvo un subconjunto de **df_cali** con 41 127 registros y las mismas 72 variables de la base original.

3.3. Filtrado por estado del caso: casos confirmados

Para evitar confusión entre casos sospechosos, probables y confirmados, y mantener coherencia con las cifras oficiales divulgadas en medios y boletines epidemiológicos, se decidió trabajar exclusivamente con los casos *confirmados*. Se utilizó la variable binaria **confirmados**, retirando aquellos registros en los que esta variable tomaba el valor 0.

El conjunto resultante, denotado **df_cali_conf**, contiene 30 386 registros de casos confirmados de dengue en Cali durante 2024 y 74 variables (incluyendo algunas variables derivadas creadas en el preprocesamiento).

La Tabla 1 resume el proceso de filtrado aplicado a la base de microdatos.




Figura 1: Casos semanales de dengue confirmados en Cali durante 2024. Los puntos representan los conteos observados C_t a partir de la base SIVIGILA filtrada.

3.4. Construcción de la serie temporal semanal

El modelo SIR discreto trabaja con unidades de tiempo semanales. Por ello, a cada registro de **df_cali_conf** se le asignó una *semana epidemiológica* utilizando como referencia la fecha de inicio de síntomas (**INI_SIN**) y, en caso de estar ausente, la fecha de notificación (**FEC_NOT**). En R se utilizó la función **epiweek()** del paquete **lubridate**.

Para cada semana $t = 1, \dots, 52$ se contó el número de casos confirmados, obteniendo así la serie temporal semanal

$$C_t, \quad t = 1, \dots, T, \quad T = 52,$$

donde C_t representa el número de casos de dengue confirmados en Cali durante la semana epidemiológica t .

Con el fin de garantizar la continuidad temporal, se completaron semanas sin registros explícitos asignándoles valor cero. Posteriormente, se construyó un *data frame* **ts_cali** con las columnas **semana** y **n**, donde **n** corresponde a C_t .

La Figura 1 muestra la evolución de los casos semanales confirmados de dengue en Cali durante 2024. Se observa un pico de incidencia en el primer semestre, seguido de una fase de descenso gradual y una cola larga hacia el final del año.

3.5. Descripción exploratoria básica

Como parte del análisis exploratorio, se calcularon estadísticas descriptivas de la serie semanal: mínimo, máximo, media, mediana y cuartiles. La Tabla 2 resume estos resultados.

Cuadro 2: Estadísticos descriptivos de la serie semanal C_t de casos confirmados de dengue en Cali (2024).

	Min	Q1	Mediana	Media	Max
C_t	0	550	820	584	1 400

(Nota: los valores de la tabla pueden ajustarse con los estadísticos computados en R.)

Estos resultados muestran que, si bien existen semanas con pocos casos, durante gran parte del año los conteos se mantienen en rangos intermedios-altos, reforzando la idea de un año epidémico para la ciudad.

4. Modelo SIR y MCMC

4.1. Modelo de proceso: dinámica SIR estocástica

En la Sección anterior se presentó la formulación discreta y estocástica del modelo SIR en términos de las variables (S_t, I_t, R_t) y de las probabilidades de infección y recuperación. En este trabajo se considera una población de tamaño constante N (población de Cali) y parámetros epidemiológicos fijos (β, γ) .

El modelo de proceso queda entonces especificado por

$$\text{new_inf}_t \sim \text{Binomial}\left(S_t, 1 - \exp\left(-\beta \frac{I_t}{N}\right)\right), \quad (12)$$

$$\text{new_rec}_t \sim \text{Binomial}(I_t, 1 - \exp(-\gamma)), \quad (13)$$

$$S_{t+1} = S_t - \text{new_inf}_t, \quad (14)$$

$$I_{t+1} = I_t + \text{new_inf}_t - \text{new_rec}_t, \quad (15)$$

$$R_{t+1} = R_t + \text{new_rec}_t. \quad (16)$$

Las condiciones iniciales se especifican mediante S_0, I_0 y R_0 , con $S_0 + I_0 + R_0 = N$. En la implementación se parametriza S_0 en términos de la fracción susceptible inicial S_0/N y se fija I_0 según los casos observados en las primeras semanas.

Esta dinámica define una Cadena de Markov $(X_t)_{t \geq 0}$ con $X_t = (S_t, I_t, R_t)$ y espacio de estados finito, tal como se discutió en el marco teórico.

4.2. Modelo de observación: vinculación con los datos de vigilancia

El modelo SIR describe la evolución del número de infectados reales I_t , pero los datos disponibles corresponden a casos *reportados* por el sistema de vigilancia en salud pública. Para conectar el proceso latente con los datos observados se introduce una *tasa de notificación* $\rho \in (0, 1)$, que representa la proporción aproximada de infecciones que llegan a ser registradas como casos confirmados.

Siguiendo la formulación utilizada en la literatura epidemiológica reciente, se supone que el número de casos observados en la semana t está dado por

$$C_t | I_t \sim \mathcal{N}(\rho I_t, (\rho I_t \tau_C)^2), \quad (17)$$

donde $\tau_C > 0$ controla el nivel de ruido en el sistema de vigilancia. Si τ_C es pequeño, los datos observados se

ajustan estrechamente a la curva latente; si τ_C es cercano a 1, se permite una desviación relativa considerable.

En la práctica, se fija $\gamma = 1$ (una semana infeccioso en promedio) y $\rho = 1/6$ basados en estudios previos, mientras que S_0, β y τ_C se tratan como parámetros desconocidos a estimar.

4.3. Especificación bayesiana

Desde una perspectiva bayesiana, se asignan distribuciones *a priori* a los parámetros de interés. En este trabajo se utilizaron los siguientes priors:

- Fracción susceptible inicial:

$$S_0/N \sim \text{Uniform}(0, 1).$$

- Parámetro de transmisión:

$$\beta \sim \mathcal{N}(\mu_\beta, \sigma_\beta^2),$$

con μ_β y σ_β elegidos de modo que reflejen valores razonables reportados en la literatura para dengue.

- Parámetro de ruido en los reportes:

$$\tau_C \sim \text{Uniform}(0, 1).$$

De esta forma se obtiene el modelo jerárquico

$$p(S_0, \beta, \tau_C | C_{1:T}) \propto p(S_0) p(\beta) p(\tau_C) \prod_{t=1}^T p(C_t | I_t, \rho, \tau_C) \prod_{t=0}^{T-1} p(X_{t+1} | X_t)$$

donde $X_{0:T}$ es la trayectoria latente de la Cadena de Markov SIR.

4.4. Implementación en JAGS y MCMC

El modelo anterior se implementó en el lenguaje JAGS (*Just Another Gibbs Sampler*), que permite especificar modelos jerárquicos de forma declarativa y utiliza algoritmos MCMC para generar muestras de la distribución posterior.

En términos generales, el archivo `sir_cali_nullmodel.jags` contiene las siguientes secciones:

- Declaración de priors para S_0, β y τ_C .
- Inicialización de los compartimentos S_1, I_1 y R_1 .
- Bucle temporal que define la dinámica SIR mediante distribuciones binomiales para nuevas infecciones y recuperaciones.
- Modelo de observación normal para los casos C_t .

En R se utilizó el paquete `rjags` para interactuar con JAGS. Se consideraron cuatro cadenas independientes, con una fase de adaptación de 80 000 iteraciones, un periodo de *burn-in* de 50 000 iteraciones adicionales y 100 000 iteraciones de muestreo por cadena, almacenando una muestra cada 10 iteraciones (*thinning*). Esto resulta en 10 000 muestras posteriores por parámetro.

La convergencia de las cadenas se evaluó mediante inspección visual de los *traceplots* y a través del estadístico potencial de reducción de escala (*Gelman–Rubin*), obteniendo valores cercanos a 1 para todos los parámetros monitoreados.

5. Resultados: parámetros, reconstrucción y diagnóstico

5.1. Estimación de parámetros epidemiológicos

La Tabla 3 resume los resultados de la distribución posterior de los parámetros S_0 , β y τ_C . Se reportan la media posterior, la desviación estándar y los cuantiles 2.5 %, 50 % (mediana) y 97.5 %.

Los resultados sugieren que la fracción susceptible inicial al comienzo de 2024 se sitúa en torno al 50 %, con un amplio intervalo creíble que va aproximadamente de 12 % a 78 %. Este rango indica un nivel potencialmente alto de población susceptible, compatible con la ocurrencia de un brote importante.

El parámetro de transmisión β presenta una mediana cercana a 3.5, indicando una dinámica de contagio intensa en el marco del modelo SIR considerado. Finalmente, el parámetro τ_C asociado al ruido en los reportes es cercano a 1, lo que implica que la variabilidad de los datos observados alrededor de la curva latente es considerable.

5.2. Reconstrucción de la dinámica SIR

A partir de las muestras posteriores de los estados latentes S_t , I_t y R_t , se reconstruyeron las trayectorias medias y los intervalos creíbles 95 % para cada compartimento.

La Figura 2 muestra la casos semanales de los casos observados C_t y los casos estimados por el modelo, aproximados mediante ρI_t . La línea sólida corresponde a la media posterior y la banda sombreada al intervalo creíble 95 %. Los puntos representan los casos semanales observados.

Se observa que, aunque el modelo reproduce cualitativamente la existencia de un pico epidémico y una fase de descenso, la escala de la curva latente ρI_t es mucho mayor que la de los datos observados. En particular, el modelo infiere volúmenes de infecciones latentes que superan ampliamente los conteos semanales, lo que sugiere que el SIR homogéneo con parámetros constantes no es capaz de capturar adecuadamente la dinámica real del dengue en Cali durante 2024.

Las Figuras 3 y 4 muestran la evolución de las fracciones susceptibles S_t/N y recuperadas R_t/N a lo largo del

año. En ambos casos se presenta la media posterior y el intervalo creíble 95 %.

Las trayectorias sugieren una disminución progresiva de la fracción susceptible a medida que avanza el brote y un aumento complementario de la fracción recuperada, como es de esperar en un modelo SIR. Sin embargo, debido a los problemas de escala ya mencionados, estas curvas deben interpretarse con cautela.

5.3. Diagnóstico de las cadenas MCMC

La Figura 5 presenta los *traceplots* y densidades marginales posteriores de los parámetros S_0 , β y τ_C para las cadenas MCMC combinadas. En todos los casos se observa una buena mezcla y ausencia de tendencias sistemáticas, lo que sugiere convergencia a la distribución estacionaria.

x

Los estadísticos potenciales de reducción de escala de Gelman–Rubin se encontraron muy próximos a 1 para todos los parámetros (valores típicos < 1.05), reforzando la evidencia de convergencia.

6. Discusión

Los resultados obtenidos permiten reflexionar tanto sobre el comportamiento epidémico del dengue en Cali durante 2024 como sobre las limitaciones del modelo SIR homogéneo utilizado.

En primer lugar, las estimaciones de la fracción susceptible inicial S_0/N sugieren que una proporción considerable de la población se encontraba en riesgo al inicio del año. Esto es consistente con el incremento observado en la incidencia y con la posibilidad de circulación de diferentes serotipos de virus del dengue a lo largo de los años, que generan patrones complejos de inmunidad parcial y reinfecciones.

En segundo lugar, el valor posterior de β indica una transmisión relativamente alta en el marco del modelo, lo que podría reflejar condiciones climáticas favorables para el vector, alta densidad poblacional y factores socioambientales que facilitan la exposición a mosquitos infectados. Sin embargo, el hecho de que el modelo requiera valores grandes de β para acomodar los datos sugiere también que parte de la variabilidad temporal se debe a factores no modelados explícitamente.

La principal limitación del enfoque adoptado se evidencia al comparar la curva latente ρI_t con los datos observados. El modelo SIR *null* tiende a inferir tamaños de brote latente mucho mayores que los conteos semanales, lo que indica un desajuste estructural. Entre las posibles causas se encuentran:

- La suposición de una población homogénea de tamaño N igual a la población total de Cali. En la práctica, la población *efectiva* en riesgo puede ser menor, concentrada en ciertos barrios o grupos socioeconómicos.

Cuadro 3: Resumen posterior de los parámetros del modelo SIR para el dengue en Cali, 2024.

Parámetro	Media	Desv. estándar	2.5 %	50 %	97.5 %
S_0/N	0.480	0.241	0.119	0.508	0.775
β	3.690	1.945	1.498	3.484	6.691
τ_C	0.969	0.035	0.880	0.984	1.000

- La ausencia de estacionalidad en la tasa de transmisión. Es sabido que el dengue está fuertemente influenciado por variables climáticas como la temperatura y la precipitación; un β constante a lo largo del año difícilmente captura cambios abruptos en el riesgo de transmisión.
- La incertidumbre respecto a la tasa de notificación ρ y la forma funcional del modelo de observación. En particular, el alto valor posterior de τ_C sugiere que el sistema de vigilancia introduce un nivel de ruido considerable, que no es trivial de modelar.

Un hallazgo particularmente revelador se observa en los gráficos de diagnóstico MCMC (Figura 5). Las trazas de los parámetros S_0 , β y τ_C no muestran un comportamiento unimodal y estable, sino que presentan claros saltos entre varios niveles aproximadamente constantes. Este patrón se refleja también en las densidades marginales posteriores, que exhiben múltiples picos bien definidos.

La presencia de múltiples modos en la distribución posterior indica que el modelo SIR con tasa de transmisión constante es estructuralmente incapaz de ajustarse a la dinámica real del dengue en Cali durante 2024. En otras palabras, el modelo debe “escoger” distintos valores de β y S_0 para distintas porciones del año, lo cual sugiere la existencia de factores temporales (por ejemplo, estacionalidad climática) que no están incorporados en la formulación actual del modelo.

Desde una perspectiva epidemiológica, este comportamiento del MCMC constituye evidencia directa de que la variación temporal de la transmisión no puede ser modelada adecuadamente mediante un parámetro β fijo. Para capturar los cambios observados en los datos sería necesario considerar una tasa de transmisión dependiente del tiempo, $\beta(t)$, tal como se hace en trabajos recientes sobre dengue que incorporan covariables climáticas o componentes estacionales.

Desde el punto de vista de las Cadenas de Markov, este ejercicio muestra cómo un modelo relativamente sencillo puede generar dinámicas complejas cuando se combina con un modelo de observación ruidoso y se estima mediante MCMC. La Cadena de Markov subyacente al modelo SIR describe la evolución de (S_t, I_t, R_t) , mientras que la Cadena de Markov definida por el algoritmo MCMC recorre el espacio de parámetros (S_0, β, τ_C) , ilustrando la interacción entre procesos de Markov en el plano de estados y en el plano de parámetros.

Como líneas de trabajo futuro, podrían considerarse las siguientes extensiones:

- Introducir estacionalidad en la tasa de transmisión, por ejemplo, mediante una parametrización de la forma $\beta(t) = U + A_1 \cos(2\pi t/52) + A_2 \sin(2\pi t/52)$, tal como se propone en estudios recientes de dengue.
- Trabajar con un tamaño de población efectiva N_{ef} menor que la población total, calibrado a partir de información adicional sobre la distribución espacial de los casos.
- Incorporar información climática (temperatura, precipitación) en el modelo, ya sea como covariables que modulan $\beta(t)$ o a través de modelos multinivel.
- Considerar modelos multicompartimentales más ricos (por ejemplo, modelos con varias clases de susceptibles o estados de exposición) que capturen reinfecciones y diferencias entre serotipos.

7. Conclusiones

En este trabajo se desarrolló un estudio de modelación estocástica del dengue en Cali durante 2024, combinando la formulación de un modelo SIR discreto como Cadena de Markov con técnicas de inferencia bayesiana basadas en MCMC e implementadas en JAGS. A partir de la base de microdatos SIVIGILA se construyó una serie semanal de casos confirmados, que sirvió como insumo para ajustar el modelo.

Desde el punto de vista de las Cadenas de Markov, el ejercicio permitió ejemplificar cómo un proceso de Markov en un espacio de estados finito puede representar la dinámica de una epidemia y cómo la estructura de transición codifica la probabilidad de nuevas infecciones y recuperaciones en cada paso de tiempo. Asimismo, se evidenció el papel de las Cadenas de Markov en el espacio de parámetros, a través del algoritmo MCMC utilizado para aproximar la distribución posterior.

En términos epidemiológicos, las estimaciones obtenidas sugieren que el brote de dengue en Cali en 2024 se produjo en un contexto de alta susceptibilidad poblacional y elevada transmisión. No obstante, la comparación detallada entre las predicciones del modelo SIR *null* y los datos observados revela que este modelo homogéneo resulta insuficiente para capturar la magnitud y forma de la epidemia, subrayando la importancia de considerar estacionalidad, heterogeneidad espacial y tasas de notificación más realistas.

Más allá de estas limitaciones, el proyecto cumplió su objetivo pedagógico: ilustrar la aplicación de las Cadenas

de Markov y de los métodos MCMC en un problema real de interés en salud pública, y servir como punto de partida para desarrollos posteriores más sofisticados en la modelación del dengue y otras enfermedades infecciosas.

Agradecimientos

El autor agradece al profesor Freddy Hernández por la orientación académica durante el curso *Cadenas de Markov y Aplicaciones*, cuya guía permitió entender de manera profunda la relación entre los modelos estocásticos y la dinámica de procesos epidémicos.

Asimismo, se expresa un agradecimiento especial al profesor Viswanathan Arunachalam, coordinador del *Semillero de Procesos Estocásticos*, por su acompañamiento, las discusiones técnicas y el apoyo permanente en el desarrollo de este proyecto.

Este trabajo también se beneficia del entorno de aprendizaje colaborativo proporcionado por el semillero y de las herramientas de software libre como R, JAGS y Overleaf, que hicieron posible la implementación computacional y la presentación de los resultados.




Figura 2: casos semanales de los casos observados de dengue confirmados en Cali (2024) y las predicciones del modelo SIR *null*. Los puntos negros corresponden a los conteos observados C_t , mientras que la banda sombreada representa el intervalo creíble del 95 % para la cantidad estimada de casos ρI_t bajo el modelo. Se observa que, aunque el modelo reproduce cualitativamente la presencia de un pico epidémico y una fase de descenso, la magnitud de ρI_t es desproporcionadamente grande en comparación con los datos observados. Esta discrepancia indica que el modelo SIR homogéneo con tasa de transmisión constante no es adecuado para describir la dinámica real del dengue en Cali durante 2024.




Figura 3: Evolución posterior de la fracción susceptible S_t/N en Cali durante 2024. La línea negra representa la media posterior y la banda gris el intervalo creíble 95 %.




Figura 4: Evolución posterior de la fracción recuperada/inmune R_t/N en Cali durante 2024. La línea negra representa la media posterior y la banda gris el intervalo creíble 95 %.




Figura 5: Diagnóstico MCMC de los parámetros del modelo SIR. La columna izquierda muestra las trazas de las cadenas para los parámetros S_0 , β y τ_C ; la columna derecha presenta las densidades marginales posteriores correspondientes. Se observa buena mezcla y ausencia de tendencias, lo que indica convergencia de las cadenas MCMC.

Referencias

- [1] R. M. Anderson and R. M. May. *Infectious Diseases of Humans: Dynamics and Control*. Oxford University Press, New York, 1992.
- [2] O. Häggström. *Finite Markov Chains and Algorithmic Applications*. Cambridge University Press, Cambridge, 2002. ISBN 9780521890515.
- [3] M. J. Keeling and P. Rohani. *Modeling Infectious Diseases in Humans and Animals*. Princeton University Press, 2008.
- [4] M. Plummer. *JAGS: A program for analysis of Bayesian graphical models using MCMC*, 2003. URL <http://www.sourceforge.net/projects/mcmc-jags>. Proceedings of the 3rd International Workshop on Distributed Statistical Computing (DSC 2003).
- [5] M. Plummer. *rjags: Bayesian Graphical Models using MCMC*, 2024. URL <https://cran.r-project.org/package=rjags>. R package version 4-16.
- [6] L. Ramirez, Y. Chen, R. Rajesh, et al. Prediction of dengue fever outbreaks using climate variability and MCMC techniques. *Scientific Reports*, 12(5949), 2022. doi: 10.1038/s41598-022-09489-y.
2. La construcción del modelo, sus supuestos y la conexión con los métodos Bayesianos utilizados para la inferencia.
3. Los resultados principales obtenidos a partir de la simulación y del ajuste mediante MCMC.
4. Las conclusiones derivadas del análisis y las limitaciones del modelo.

El video incluye la visualización del participante en un recuadro permanente, así como diapositivas, figuras y gráficos generados a partir del código del proyecto, tal como se requiere en la rúbrica de evaluación.

El video está disponible en el siguiente enlace de YouTube:

<https://youtu.be/edGFAGwAzcc>

Apéndice: Enlace al repositorio de código

Todo el código utilizado para la construcción del modelo SIR discreto, el preprocesamiento de los datos SIVIGILA, la implementación del modelo en JAGS y la generación de las figuras del documento se encuentra disponible públicamente en el siguiente repositorio:

github.com/elbejaranog-runner/...

El repositorio incluye:

- Scripts en R para limpieza y construcción de la serie semanal.
- El archivo `sir_cali_nullmodel.jags` con la especificación del modelo.
- Código para ajuste vía `rjags` y extracción de posteriores.
- Código para generación de las figuras y tablas incluidas en el documento.

Este apéndice se incluye de manera obligatoria conforme a las instrucciones de la asignatura, garantizando transparencia y reproducibilidad del análisis.

1. El problema abordado: modelamiento de la dinámica del dengue en Cali (2024) mediante un modelo SIR formulado como una Cadena de Markov.